

# Statistik

CH.4 - Zweidimensionale Verteilungen

SS 2021 | | Prof. Dr. Buchwitz, Sommer, Henke

Wir geben Impulse

## Ausgangspunkt:

- Jede statistische Eineinheit einer Grundgesamtheit trägt eine Vielzahl von Merkmalen.
- In diesem Kapitel werden zwei Merkmale gleichzeitig untersucht.
- Bei der Darstellung und Analyse von Abhängigkeiten zwischen Variablen muss das Skalenniveau berücksichtigt werden.

## Beispiel:

- Studierende
  - Beispiel: Körpergröße und Gewicht → Streudiagramm
  - Beispiel: Geschlecht und Studiengang → Kontingenztafel
- Kraftfahrzeuge
  - Beispiel: Höchstgeschwindigkeit und Motorleistung
  - Beispiel: Kraftstoffverbrauch und Getriebart (Manuell/Automatik)


## 1 Streudiagramme

## 2 Kovarianz und Korrelation

# Beispiel: Streudiagramm

| Größe (m) | Gewicht (kg) |
|-----------|--------------|
| 1.63      | 68           |
| 1.51      | 81           |
| 1.56      | 72           |
| 1.95      | 128          |
| 1.80      | 60           |
| 1.79      | 64           |
| 1.78      | 94           |
| 1.68      | 62           |
| 1.89      | 109          |
| 1.61      | 75           |
| 1.89      | 76           |
| 1.97      | 126          |
| 1.61      | 98           |
| 1.57      | 71           |
| 1.83      | 66           |
| 1.80      | 111          |
| 1.72      | 89           |
| 1.52      | 76           |
| 1.54      | 45           |

R-Befehl: `plot()`



## 1 Streudiagramme

## 2 Kovarianz und Korrelation

$$s_{XY} = \text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})$$

- Die oben stehende Formeln gibt die Kovarianz zwischen X und Y an.
- Das Vorzeichen der Kovarianz ist ein Indikator für die Richtung eines bestehenden **linearen** Zusammenhanges zwischen Y und X.
- Die Kovarianz erlaubt es nicht Aussagen über die Stärke eines Zusammenhanges zu treffen.
- Die Größe der Kovarianz ist Abhängig von der zugrundeliegenden Einheit. Einheitenwechsel (z.B. von Euro zu TEuro) führen zu einer Wertveränderung.
- **R-Befehl:** `cov()`

$$\text{Cor}(Y, X) = \frac{1}{n-1} \sum_{i=1}^n \left( \frac{y_i - \bar{y}}{s_y} \right) \left( \frac{x_i - \bar{x}}{s_x} \right) = \frac{\text{Cov}(Y, X)}{s_y s_x} = \frac{s_{XY}}{s_x \cdot s_y}$$

- Der Korrelationskoeffizient ist ein Maß für die Stärke des linearen Zusammenhanges.
- Im Unterschied zur Kovarianz, ist  $\text{Cor}(Y, X)$  nicht skalenabhängig und erlaubt die Einschätzung von Stärke und Richtung eines linearen Zusammenhanges.
- **R-Befehl:** `cor()`

$\text{Cor}(Y, X) = 0$  bedeutet nicht, dass es zwischen  $X$  und  $Y$  keinen Zusammenhang gibt.

- 1 Wertebereich:  $-1 \leq r_{XY} \leq 1$
- 2 Ist  $r_{XY} = 0$ , so sind  $X$  und  $Y$  nicht korreliert (unkorreliert).
- 3 Ist  $r_{XY} > 0$ , so sind  $X$  und  $Y$  gleichläufig (gleichsinnig) korreliert.
- 4 Ist  $r_{XY} < 0$ , so sind  $X$  und  $Y$  gegenläufig (ungleichsinnig) korreliert.
- 5 Je größer  $|r_{XY}|$  ist, desto stärker ist die Korrelation zwischen  $X$  und  $Y$ .




**Scheinkorrelation:** obwohl ein großer Wert des Korrelationskoeffizienten zwischen  $X$  und  $Y$  besteht, liegt kein *ursächlicher* (und/oder sachlogischer) Zusammenhang zwischen  $X$  und  $Y$  vor.

## Beispiel

Zusammenhang zwischen Kindergeburten und der Anzahl der Storchente, die sich in einer Region ansiedeln.

## US Spending on science, space, and technology and Suicides by hangig, strangulation and suffocation

korrelation: 0.9921



■ Weitere Beispiele unter: <http://tylervigen.com/spurious-correlations>

- Welche Darstellungsmöglichkeiten gibt es für zweidimensionale Daten?
- Bedeutet ein Korrelationskoeffizient nah bei 1, dass ein sachlicher Zusammenhang zwischen den untersuchten Merkmalen besteht?
- Wie ist ein Korrelationskoeffizient nah bei -1 zu interpretieren?