

# Statistik

CH.11 - Regression

SS 2021 | | Prof. Dr. Buchwitz, Sommer, Henke

Wir geben Impulse

**1** Evaluation

**2** Konfidenzintervalle

**3** Hypothesentests

# EVALUATION

**1** Evaluation

**2** Konfidenzintervalle


**3** Hypothesentests

- Bei statistischen Untersuchungen ist es häufig nicht möglich (oder zu aufwändig und teuer) Informationen über alle Elemente der Grundgesamtheit zu erheben.
- Daher werden die gewünschten Informationen bei einer Teilmenge der Grundgesamtheit, einer **Stichprobe** erhoben.
- **Ziel** ist es dann, mit Hilfe der statistischen Parameter der *Stichprobe* (Mittelwert, Varianz, Verteilung) auf die statistischen Parameter der Grundgesamtheit zu **schließen**.
- Parameter der Grundgesamtheit:  $\mu, \sigma, \pi$
- Parameter der Stichprobe:  $\bar{x}, s^2, p$

# Von der Stichprobe zur Grundgesamtheit

**GG:**  $\mu, \sigma, \pi, N$

**SP:**  $\bar{x}, s^2, p, n$



## Erwartungswert

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{oder} \quad \mu = \frac{1}{N} \sum_{i=1}^N x_i$$


## Varianz

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{oder} \quad \sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

- Die korrekte Auswahl einer Stichprobe ist Gegenstand der **Stichprobentheorie**.
- Eine reine Zufallsauswahl liefert eine **repräsentative** Stichprobe.
- **Representativität** kann mit **Strukturgleichheit** übersetzt werden.
- Sofern eine echte Zufallsstichprobe nicht möglich ist wird häufig auf einen Stichprobenplan und eine damit verbundene Quotenauswahl zurückgegriffen.



- Bei Schätzungen wird zwischen Punkt- und Intervallschätzungen unterschieden. **Punktschätzer** sind ein spezifischer Wert
  - Als Punktschätzer für den Mittelwert der Grundgesamtheit  $\mu$  wird der Mittelwert der Stichprobe  $\bar{x}$  verwendet.
  - Als Punktschätzer für die Varianz der Grundgesamtheit  $\sigma^2$  wird  $s^2$  der Stichprobe verwendet.
  - Als Punktschätzer für einen Anteilswert  $\pi$  der Grundgesamtheit wird der prozentuale Anteil  $p$  in der Stichprobe verwendet.



- Intervallschätzer geben einen Bereich an in dem der wahre aber unbekannte (und damit zu schätzende) Parameter mit einer bestimmten Wahrscheinlichkeit liegt.
- Die Wahrscheinlichkeit, dass der wahre aber unbekannte Parameter zwischen Untergrenze  $U$  und Obergrenze  $O$  liegt bezeichnen wir als  $\alpha$ , also:  $P(U \leq x \leq O) = 1 - \alpha$
- Am rechten und linken Rand der Verteilung (eingezeichneter Bereich) liegt jeweils  $\alpha/2$  der Wahrscheinlichkeitsmasse, also  $P(X \leq U) = \alpha/2$  und  $P(X > O) = \alpha/2$ .

Intervallschätzer werden (fast) immer symmetrisch um Punktschätzer konstruiert.

Im weiteren Verlauf diskutieren wir die folgenden Konfidenzintervalle, die hinsichtlich der aufgelisteten Fallunterscheidungen differenziert werden können. Vor der Berechnung muss zunächst geklärt werden, welche Art von Konfidenzintervall gefragt ist:

## 1) Konfidenzintervalle für Mittelwerte

- Anwendungsfall mit **bekannter Varianz der Grundgesamtheit** ( $\sigma^2$  bekannt)
- Anwendungsfall mit **unbekannter Varianz der Grundgesamtheit** (Schätzung mittels  $s^2$ )

## 2) Konfidenzintervalle für Anteilswerte


- Wenn die Grundgesamtheit einer Normalverteilung folgt, dann sind die Mittelwerte von Stichproben mit Umfang  $n \ll N$  ebenfalls normalverteilt. Es gilt  $\bar{x} \sim N(\mu, \frac{\sigma^2}{n})$
- Bei großen Stichproben ( $n \geq 30$ ) sind die Mittelwerte näherungsweise normalverteilt.

- **Voraussetzung:** Normalverteilte Grundgesamtheit oder große Stichprobe ( $n > 30$ ).
- **Fall:** Varianz der Grundgesamtheit  $\sigma^2$  bekannt.
- Das zweiseitige, symmetrische Konfidenzintervall  $[\underline{\mu}, \overline{\mu}]$  zum Konfidenzniveau  $1 - \alpha$  ist gegeben durch:

$$\underline{\mu}, \overline{\mu} = \bar{x} \pm z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}$$

**Aufgabe:** Das Ergebnis einer Studie mit 100 Ganztagsschülern besagt, dass diese durchschnittlich 52 h/Woche in der Schule verbringen. Aus früheren Untersuchungen ist bekannt, dass die Standardabweichung der wöchentlichen Aufenthaltszeit in der Schule 12 Stunden beträgt.

- Geben Sie ein 95% Konfidenzintervall für die durchschnittliche wöchentliche Aufenthaltszeit in der Ganztagsschule an.
- **Hinweis:** Eine Verteilungstabelle befindet sich auf der nächsten Seite.



# Verteilungsfunktion $F(z)$ für $z \sim N(\mu = 0, \sigma^2 = 1)$

Verteilungsfunktion  $F(z)$  der Standardnormalverteilung  $N(0, 1)$

Beispiel:  $F(z) = P(z \leq 1.96) = 0.9750$

z	0	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916




- **Voraussetzung:** Normalverteilte Grundgesamtheit oder große Stichprobe ( $n > 30$ ).
- **Fall:** Varianz der Grundgesamtheit unbekannt.
- Das zweiseitige, symmetrische Konfidenzintervall  $[\underline{\mu}, \overline{\mu}]$  zum Konfidenzniveau  $1 - \alpha$  ist gegeben durch:

$$\underline{\mu}, \overline{\mu} = \bar{x} \pm t_{n-1, 1-\frac{\alpha}{2}} \cdot \frac{s}{\sqrt{n}}$$

**Aufgabe:** Nehmen Sie an, dass die Varianz der wöchentlichen Aufenthaltszeit in der Ganztags der vorherigen Studie ( $n = 100$ ,  $\bar{x} = 52$ ) auf Basis der Stichprobe mit 144  $(h/\text{Woche})^2$  geschätzt wurde.

- Geben Sie ein 95% Konfidenzintervall für die durchschnittliche wöchentliche Aufenthaltszeit in der Ganztagsschule an.
- **Hinweis:** Eine Verteilungstabelle befindet sich auf der nächsten Seite.




# Quantile der $t_{n,\gamma}$ Verteilung

Quantile $t_{n,\gamma}$ der $t_n$ -Verteilung							
Beispiel: $P(t_{10} \leq 0.6998) = 0.750$							
$n \setminus \gamma$	0.995	0.99	0.975	0.95	0.9	0.75	0.5
1	63.6567	31.8205	12.7062	6.3138	3.0777	1.0000	0
2	9.9248	6.9646	4.3027	2.9200	1.8856	0.8165	0
3	5.8409	4.5407	3.1824	2.3534	1.6377	0.7649	0
4	4.6041	3.7469	2.7764	2.1318	1.5332	0.7407	0
5	4.0321	3.3649	2.5706	2.0150	1.4759	0.7267	0
6	3.7074	3.1427	2.4469	1.9432	1.4398	0.7176	0
7	3.4995	2.9980	2.3646	1.8946	1.4149	0.7111	0
8	3.3554	2.8965	2.3060	1.8595	1.3968	0.7064	0
9	3.2498	2.8214	2.2622	1.8331	1.3830	0.7027	0
10	3.1693	2.7638	2.2281	1.8125	1.3722	0.6998	0
20	2.8453	2.5280	2.0860	1.7247	1.3253	0.6870	0
30	2.7500	2.4573	2.0423	1.6973	1.3104	0.6828	0
40	2.7045	2.4233	2.0211	1.6839	1.3031	0.6807	0
50	2.6778	2.4033	2.0086	1.6759	1.2987	0.6794	0
60	2.6603	2.3901	2.0003	1.6706	1.2958	0.6786	0
70	2.6479	2.3808	1.9944	1.6669	1.2938	0.6780	0
80	2.6387	2.3739	1.9901	1.6641	1.2922	0.6776	0
90	2.6316	2.3685	1.9867	1.6620	1.2910	0.6772	0
100	2.6259	2.3642	1.9840	1.6602	1.2901	0.6770	0
100	2.6259	2.3642	1.9840	1.6602	1.2901	0.6770	0
150	2.6090	2.3515	1.9759	1.6551	1.2872	0.6761	0
200	2.6006	2.3451	1.9719	1.6525	1.2858	0.6757	0
250	2.5956	2.3414	1.9695	1.6510	1.2849	0.6755	0
300	2.5923	2.3388	1.9679	1.6498	1.2844	0.6753	0

- **Voraussetzung:**  $n \cdot p \geq 5$  und  $n \cdot (1 - p) \geq 5$
- Das zweiseitige, symmetrische Konfidenzintervall  $[\underline{\pi}, \overline{\pi}]$  zum Konfidenzniveau  $1 - \alpha$  ist gegeben durch:

$$\underline{\pi}, \overline{\pi} = p \pm z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{p \cdot (1 - p)}{n}}$$

- Konfidenzintervalle geben die Überdeckungswahrscheinlichkeit mit dem wahren aber unbekannten Parameter der Grundgesamtheit an.



**1** Evaluation

**2** Konfidenzintervalle

**3** Hypothesentests

**Beispiel:** Eine Reifenfirma wirbt damit, dass die durchschnittliche Lebensdauer einer angebotenen Reifenmarke 100 000 km übersteigt.

Wie prüft man das?

**Beispiel:** Eine Reifenfirma wirbt damit, dass die durchschnittliche Lebensdauer einer angebotenen Reifenmarke 100 000 km übersteigt.

## Wie prüft man das?

Überlegungen zu Ergebnissen aus einer Stichprobe:

- $\bar{x} \geq 100000\text{km}$  → Der Werbung kann man glauben.
- $\bar{x} = 99500\text{km}$  → Nah genug um der Werbung noch zu glauben.
- $\bar{x} = 60000\text{km}$  → Zweifel an der Aussage.

Das Testen von Hypothesen ist eine Systematisierung des diskutierten Vorgehens.



Beim Testen von Hypothesen werden **zwei** Hypothesen aufgestellt.

Hypothesentests sind fast immer *konservativ* aufgebaut:

- Die **Nullhypothese**  $H_0$ , ist die Hypothese die man (üblicherweise) verwerfen möchte.
- Die **Alternativhypothese**  $H_A$  (oder  $H_1$ ), bildet das Gegenteil der Nullhypothese ab und beinhaltet die Aussage, die man zeigen möchte.

**Beispiele:**

- a)  $H_0 : \mu = 25$  vs.  $H_A : \mu \neq 25$
- b)  $H_0 : \mu \leq 25$  vs.  $H_1 : \mu > 25$
- c)  $H_0 : \mu \geq 25$  vs.  $H_1 : \mu < 25$
- d)  $H_0$  : Medikament wirkt gegen Krankheit vs.  $H_1$  : Medikament wird nicht gegen Krankheit

## Fehler 1. Art ( $\alpha$ ) und Fehler 2. Art ( $\beta$ )

	$H_0$ beibehalten	$H_0$ verwerfen
$H_0$ wahr	korrekt $P = 1 - \alpha$	Fehler 1. Art $P = \alpha$
$H_A$ wahr	Fehler 2. Art $P = \beta$	korrekt $P(1 - \beta)$

	Angeklagten freisprechen	Angeklagten verurteilen
Angeklagter unschuldig	korrekt $P = 1 - \alpha$	Fehler 1. Art $P = \alpha$
Angeklagter schuldig	Fehler 2. Art $P = \beta$	korrekt $P(1 - \beta)$

- Wie können Sie den Fehler erster Art  $\alpha$  minimieren, sodass  $\alpha = 0$ ?
- Was passiert mit dem Fehler zweiter Art  $\beta$ ?

- 1) Formulieren Sie Nullhypothese  $H_0$  und Alternativhypothese  $H_A$ .
- 2) Legen Sie ein Signifikanzniveau  $\alpha$  fest.
- 3) Wählen Sie die passende Teststatistik.
- 4) Bestimmen Sie den Wert der Teststatistik, ab dem die Nullhypothese verworfen werden muss.
- 5) Bestimmen Sie den Vergleichswert aus den Stichprobendaten.
- 6) Entscheiden Sie durch Vergleich der Werte aus (iv) und (v), ob Sie die Nullhypothese verwerfen können.

- Ein Unternehmen erwägt die Einführung eines neuen Zahlungssystems.
- Der Business Case für das Projekt hat ergeben, dass sich die Einführung des Zahlungssystems nur dann lohnt, wenn der durchschnittliche Monatsumsatz pro Kunde mehr als 70 Euro beträgt. Eine Stichprobe von 200 Kunden ergab einen durchschnittlichen Umsatz von 74 Euro pro Kunde.
- Kann man unter der Annahme einer Normalverteilung mit  $\sigma = 30$  Euro mit 95%-iger Sicherheit davon ausgehen, dass sich die Einführung des Zahlungssystems für das Unternehmen lohnt?

$$H_0 : \mu \leq \mu_0 \text{ vs. } H_A : \mu > \mu_0$$

**Testvorschrift:**

Verwerfe  $H_0$ , wenn gilt:

$$\bar{x} \geq \mu_0 + z_{1-\alpha} \cdot \frac{\sigma}{\sqrt{n}}$$

$$H_0 : \mu \leq \mu_0 \text{ vs. } H_A : \mu > \mu_0$$


**Testvorschrift:**

Verwerfe  $H_0$ , wenn gilt:

$$\bar{x} \geq \mu_0 + z_{1-\alpha} \cdot \frac{\sigma}{\sqrt{n}}$$

- Alternativ können Sie die Formel auch direkt umstellen:

$$\frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \geq z_{1-\alpha}$$









- 1 Beschreiben Sie den Unterschied zwischen Stichprobe und Grundgesamtheit? Wozu dienen Stichproben?
- 2 Erläutern Sie in eigenen Worten was ein Konfidenzintervall ist und wie diese interpretiert werden können.
- 3 Wovon ist die Breite eines Konfidenzintervalls abhängig?