

Statistik

CH.12 - Regression

SS 2022 | | Prof. Dr. Buchwitz, Sommer, Henke

Wir geben Impulse

- Ziel 1
- Ziel 2
- Ziel 3

- **Ziel:** Erkennen von Abhängigkeiten und Zusammenhängen zwischen mehreren Merkmalen und Modellierung der Effektgrößen der Zusammenhänge.
- **Beispiele:**
 - ▶ Umsatz und Werbeetat einer Supermarktkette: *Hängt der Umsatz von den eingesetzten Werbemitteln ab?*
 - ▶ Körpergröße und Gewicht von Personen: *Ist das Gewicht einer Person von dessen Körpergröße abhängig?*
 - ▶ Benzinpreis und Mineralölpreis: *Ist der deutsche Benzinpreis eine Funktion des globalen Mineralölpreises?*

Sind die beiden gezeigten Größen voneinander Abhängig?

| ## | | x | y |
|----|-------|--------|-------|
| ## | [1,] | 5.310 | 32.24 |
| ## | [2,] | 7.442 | 35.42 |
| ## | [3,] | 11.457 | 41.16 |
| ## | [4,] | 18.164 | 52.88 |
| ## | [5,] | 4.034 | 28.82 |
| ## | [6,] | 17.968 | 53.04 |
| ## | [7,] | 18.894 | 50.25 |
| ## | [8,] | 13.216 | 44.26 |
| ## | [9,] | 12.582 | 44.82 |
| ## | [10,] | 1.236 | 27.19 |
| ## | [11,] | 4.119 | 33.19 |
| ## | [12,] | 3.531 | 30.15 |
| ## | [13,] | 13.740 | 46.87 |
| ## | [14,] | 7.682 | 39.24 |
| ## | [15,] | 15.397 | 46.37 |
| ## | [16,] | 9.954 | 36.72 |
| ## | [17,] | 14.352 | 46.65 |
| ## | [18,] | 19.838 | 54.17 |
| ## | [19,] | 7.601 | 35.04 |
| ## | [20,] | 15.549 | 47.24 |
| ## | [21,] | 18.694 | 51.42 |
| ## | [22,] | 4.243 | 33.18 |
| ## | [23,] | 13.033 | 47.43 |
| ## | [24,] | 2.511 | 31.25 |
| ## | [25,] | 5.344 | 31.94 |

Datenbeschreibung

x Berufserfahrung in Jahren

y Gehalt in Euro

Sind die beiden gezeigten Größen voneinander Abhängig?



$$Y = f(X) + \epsilon$$

- Wir betrachten zunächst den einfachen Fall, bei dem die abhängige Variable Y durch **eine** unabhängige Variable X erklärt wird. Unabhängige Variablen bezeichnet man auch als Regressoren oder Prädiktoren.
- ϵ bezeichnet den Anpassungsfehler und wird Fehlerterm oder Residuum genannt.
- Wir verzichten auf die vollständige Herleitung der gezeigten Formeln und fokussieren auf die zugrundeliegenden Mechanismen und die zugehörige Intuition.

Salary vs. Experience



Aufgabe: Bestimmen des Vorzeichens

- $y_i - \bar{y}$ ist die Differenz jeder Beobachtung y_i vom arithmetischen Mittel der abhängigen Variablen
- $x_i - \bar{x}$ ist die Abweichung x_i vom arithmetischen Mittel des Prädiktors
- $(y_i - \bar{y})(x_i - \bar{x})$ ist das Produkt der vorherigen beiden Größen

| Quadrant | $y_i - \bar{y}$ | $x_i - \bar{x}$ | $(y_i - \bar{y})(x_i - \bar{x})$ |
|------------------|-----------------|-----------------|----------------------------------|
| 1 (top right) | | | |
| 2 (top left) | | | |
| 3 (bottom left) | | | |
| 4 (bottom right) | | | |

Positiver Zusammenhang

- Wenn der Zusammenhang zwischen Y und X **positiv** ist (also wenn X größer wird, dann wird auch Y größer), dann sind mehr Datenpunkte im ersten und dritten Quadranten als im zweiten und vierten.
- Die Summe der Elemente in der letzten Spalte der vorherigen Tabelle ist dann mit großer Wahrscheinlichkeit positiv, also $\text{Cov}(Y, X) > 0$.

Positiver Zusammenhang

- Wenn der Zusammenhang zwischen Y und X **positiv** ist (also wenn X größer wird, dann wird auch Y größer), dann sind mehr Datenpunkte im ersten und dritten Quadranten als im zweiten und vierten.
- Die Summe der Elemente in der letzten Spalte der vorherigen Tabelle ist dann mit großer Wahrscheinlichkeit positiv, also $\text{Cov}(Y, X) > 0$.

Negativer Zusammenhang

- Wenn der lineare Zusammenhang zwischen Y und X **negativ** ist (z.B. wenn X sinkt, steigt Y), dann befinden sich mehr Datenpunkte im zweiten und vierten Quadranten als im ersten und dritten.
- Die Summe der Elemente in der letzten Spalte der vorherigen Tabelle ist dann mit großer Wahrscheinlichkeit negativ, also $\text{Cov}(Y, X) < 0$.

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})$$

- Die aufwändig berechnete Größe ist die Kovarianz zwischen Y und X.
- Das Vorzeichen der Kovarianz gibt die Richtung des Zusammenhangs zwischen Y und X an.
- Die Kovarianz gibt **nur die Richtung des Zusammenhangs an** und erlaubt keine Beurteilung der Stärke dieses Zusammenhangs.
- Die Kovarianz verändert sich mit Veränderungen der Einheit der Daten (z.B. von Euro in TEuro).

Your turn

Wie ändert sich die Kovarianz, wenn Sie $\text{Cov}(X, Y)$ anstelle von $\text{Cov}(Y, X)$ berechnen?

$$\text{Cor}(Y, X) = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{y_i - \bar{y}}{s_y} \right) \left(\frac{x_i - \bar{x}}{s_x} \right) = \frac{\text{Cov}(Y, X)}{s_y s_x}$$

- $\text{Cor}(Y, X)$ kann auf zwei Arten interpretiert werden:
 - ▶ als Kovarianz der z-Standardisierten Variablen X und Y .
 - ▶ als Verhältnis von Kovarianz zum Produkt der Standardabweichungen der Variablen.
- Im Gegensatz zur Kovarianz ist $\text{Cor}(Y, X)$ skaleninvariant mit einem Wertebereich von $-1 \geq \text{Cor}(Y, X) \geq 1$ und erlaubt daher die Beurteilung von **Richtung** und **Stärke** des Zusammenhangs.

```
cov(y, x)
```

```
## [1] 49.67
```

```
cor(y, x)
```

```
## [1] 0.981
```

Verwendung des Zusammenhangs

Kovarianz und Korrelationskoeffizient können nicht für Vorhersagen (X gegeben und Y gesucht) verwendet werden!

$$Y = \beta_0 + \beta_1 X + \epsilon$$

- Regressionsanalyse ist eine Erweiterung der Korrelationsanalyse und erlaubt es den Zusammenhang zwischen abhängiger und unabhängigen Variablen numerisch zu beschreiben.
- β_0 und β_1 sind Konstanten, die als **Regressionskoeffizienten** bezeichnet werden, ϵ ist der Fehlerterm
 - ▶ β_0 ist der Achsenabschnitt und ist der vorhergesagte Wert, wenn $X = 0$.
 - ▶ β_1 ist die Steigung und kann interpretiert werden als Änderung in Y , wenn X sich um eine Einheit erhöht.

Wie bestimmen wir
Werte für β_0 und β_1 ?

Salary vs. Experience




Salary vs. Experience



Residuen: Wieso ist die eingezeichnete Gerade optimal?

Salary vs. Experience



Residuen: Wieso ist die eingezeichnete Gerade optimal?

Salary vs. Experience



Minimieren:
$$S(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 \cdot x_i))^2$$

$$S(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 \cdot x_i))^2$$

- Die quadratische Funktion $S(\beta_0, \beta_1)$ muss minimiert werden und liefert dann die Lösung $\hat{\beta}_0$ und $\hat{\beta}_1$. Diese Werte werden zuweilen auch mit b_0 und b_1 bezeichnet.
- Die Werte $\hat{\beta}_0 = b_0$ und $\hat{\beta}_1 = b_1$ werden **Kleinste-Quadrate-Schätzer** (Ordinary Least Squares Estimates, OLS Estimates) genannt und spezifizieren die Gerade mit der kleinsten möglichen Summe der quadrierten vertikalen Distanzen zu den Beobachtungen.

- Die mit der Methode der kleinsten Quadrate bestimmten Regressionslinie existiert immer und ist gegeben durch:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$$

- Mit Hilfe der Beobachtungsgleichung können die angepassten Werte (fitted Values) berechnet werden:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad \text{for } i = 1, 2, \dots, n$$

- Jeder Punkt (x_i, \hat{y}_i) **liegt auf der Regressionsgerade.**
- Die zugehörigen Residuen (Ordinary Least Squares Residuals) geben die vertikale Distanz zwischen Beobachtung und Gerade (Anpassungsfehler) an und können wie folgt berechnet werden:

$$\hat{\epsilon}_i = y_i - \hat{y}_i \quad \text{for } i = 1, 2, \dots, n$$

- Für die Lösung des Minimierungsproblems gibt es eine analytische Lösung:

$$\hat{\beta}_1 = b_1 = \frac{\sum (y_i - \bar{y})(x_i - \bar{x})}{\sum (x_i - \bar{x})^2} \quad \text{und} \quad \hat{\beta}_0 = b_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Herleitung der Formeln:

- Minimierung der quadratischen Funktion $S(\beta_0, \beta_1)$ mit Hilfe der Differentialrechnung
- Bildung der partiellen Ableitungen nach b_0 und b_1
- Setzen der Ableitungen = 0
- Lösen des resultierenden Gleichungssystems
- Die gezeigten Formeln sind die erhaltene Lösung

Lineare Regression

```
summary(x) # Experience in Years
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1.24   5.31   11.46   10.64   15.40   19.84
```

```
summary(y) # Salary in Euro
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      27.2   33.2   41.2   40.8   47.2   54.2
```

```
cor(y,x)
```

```
## [1] 0.981
```

```
lm(y ~ 1 + x)
```

```
##
## Call:
## lm(formula = y ~ 1 + x)
##
## Coefficients:
## (Intercept)          x
##      25.60       1.43
```

- Die bestimmte Gerade beschreibt die Daten der **Stichprobe**. Interessant ist jedoch die Frage, ob der Zusammenhang auch verallgemeinert werden und für die Grundgesamtheit angenommen werden kann.
- Prüfen der Hypothese $\beta_1 = 0$ is equivalent zur Aussage, dass **kein linearer Zusammenhang** vorhanden ist.
- Sollte $\beta_1 > 0$ oder $\beta_1 < 0$ gelten (Annahme der entsprechenden Alternativhypothese) liefert **Evidenz** (keinen Beweis) für die Existenz eines linearen Zusammenhangs.

- Unter der Annahme, dass die Residuen **unabhängig und gleich verteilt** (i.i.d.) sind ($\epsilon \sim N(0, \sigma^2)$), kann die Residualvarianz σ^2 geschätzt werden.

$$\hat{\sigma}^2 = \frac{\sum \epsilon_i^2}{n-2} = \frac{\sum (y_i - \hat{y}_i)^2}{n-2} = \frac{SSE}{n-2}$$

- Mit Hilfe der geschätzten Residualvarianz $\hat{\sigma}^2$ kann der Standardfehler (s.e.) der Regressionsparameter geschätzt werden.

$$s.e.(\hat{\beta}_0) = \hat{\sigma}^2 \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2}} \quad \text{und} \quad s.e.(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{\sqrt{\sum (x_i - \bar{x})^2}}$$

- Unter der Annahme der Normalverteilung kann der t -Test für die Regressionskoeffizienten durchgeführt werden:

$$H_0 : \beta_1 = 0 \quad \text{versus} \quad H_1 : \beta_1 \neq 0$$

- Die Teststatistik t folgt einer t -Verteilung mit $n-2$ Freiheitsgraden. Ergänzend muss noch eine Irrtumswahrscheinlichkeit α für den Test festgelegt werden.

$$t_1 = \frac{\hat{\beta}_1}{s.e.(\hat{\beta}_1)}$$

- Die Nullhypothese $\beta_1 = 0$ kann für eine gegebene Irrtumswahrscheinlichkeit α verworfen werden, wenn gilt:

$$|t| \geq t_{(n-2, 1-\alpha/2)}$$

Lineare Regression

```
summary(lm(y ~ 1 + x))
```

```
##
## Call:
## lm(formula = y ~ 1 + x)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.141 -0.966 -0.270  1.502  3.158
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   25.601      0.714    35.8   <2e-16 ***
## x              1.433      0.059    24.3   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.7 on 23 degrees of freedom
## Multiple R-squared:  0.962, Adjusted R-squared:  0.961
## F-statistic: 589 on 1 and 23 DF, p-value: <2e-16
```

Welche Gerade hat eine höhere Anpassungsgüte und bildet daher den Sachverhalt in den Daten präziser ab?

(a)



(b)



Definition von Streugrößen:

$$SST = \sum (y_i - \bar{y})^2 \quad SSR = \sum (\hat{y}_i - \bar{y})^2 \quad SSE = \sum (y_i - \hat{y}_i)^2$$

- Sum of Squares Total (SST) ist die gesamte Abweichung von Y vom zugehörigen arithmetischem Mittel \bar{y} .
- Sum of Squares Regression (SSR) ist die erklärte Variation, die durch die Regressionsgerade abgebildet werden kann
- Sum of Squares Error (SSE) ist die unerklärte Streuung und die Varianz der Residuen.

- **SSR**, misst die Qualität von X als Prädiktor für Y
- **SSE**, misst den Fehler in dieser Prädiktion
- Das Verhältnis $R^2 = SSR/SST$ ist der Anteil der durch X erklärten Varianz an der totalen Varianz. Zur Beurteilung der Anpassungsgüte einer Regressionsgerade kann entsprechend das Bestimmtheitsmaß R^2 herangezogen werden.

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} = [\text{Cor}(Y, \hat{Y})]^2$$

- Es gilt $0 \leq R^2 \leq 1$ und je näher R^2 an 1 liegt, desto intensiver ausgeprägt ist der lineare Zusammenhang.

Im Fall von nur einem einzigen Prädiktor gilt zudem $[\text{Cor}(Y, X)]^2$!

Lineare Regression

```
summary(lm(y ~ 1 + x))
```

```
##
## Call:
## lm(formula = y ~ 1 + x)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.141 -0.966 -0.270  1.502  3.158
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   25.601      0.714    35.8   <2e-16 ***
## x              1.433      0.059    24.3   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.7 on 23 degrees of freedom
## Multiple R-squared:  0.962, Adjusted R-squared:  0.961
## F-statistic: 589 on 1 and 23 DF, p-value: <2e-16
```

- Wozu wird die Methoden der linearen Regression verwendet?
- Was ist die zugrundeliegende Methodik zur Bestimmung der Parameter der Regressionsgeraden?
- Wozu dient das Bestimmtheitsmaß R^2 ?